
MACHINE LEARNING APPLIED IN THE EVALUATION OF AIRPORT PROJECTS

Ítalo Guedes¹, Max Andrade¹, Cleber Zanchettin²

¹Universidade Federal de Pernambuco (UFPE), ²Centro de Informática Universidade Federal de Pernambuco (UFPE)

* Corresponding author e-mail address: italo.guedes@ufpe.br

PAPER ID: SIT214

RESUMO

O Brasil é um país com dimensões continentais, tendo o transporte aéreo como um vetor estratégico no desenvolvimento econômico. Em virtude de uma conjugação favorável de fatores, tais como: dimensão territorial, alta mobilidade geográfica e social, dentre outros, o Brasil tornou-se um dos países emergentes com elevado potencial de desenvolvimento do transporte aéreo. No que diz respeito ao desenvolvimento de um projeto aeroportuário no Brasil, uma série de pré-requisitos normativos norteiam os projetistas durante o desenvolvimento. Dentre os documentos, pode-se destacar: i) RBAC (Regulamento Brasileiro de Aviação Civil), ii) Manual de Projetos Aeroportuários, iii) Anexo 14, iv) Manual de Critérios e Condições de Planejamento Aeroportuário, entre outros. Tendo em vista a quantidade elevada de documentos normativos a serem considerados na fase de desenvolvimento de um projeto aeroportuário, faz-se necessário que a equipe de analistas de projeto disponha de expertise para realizar a avaliação desses projetos. Na situação atual, o processo de avaliação e aprovação tende a perdurar meses e, em alguns casos, até anos, até a aprovação final do projeto. Este artigo apresenta resultados parciais de uma pesquisa de doutorado em desenvolvimento que utiliza técnicas de Aprendizagem de Máquina na fase de avaliação de projetos aeroportuários a partir de dados contidos nos modelos digitais de aeroportos baseado na Modelagem da Informação da Construção (BIM). Os resultados preliminares desta pesquisa demonstram a utilização de três algoritmos de aprendizagem supervisionada conseguindo obter uma acurácia de predição acima de 90%.

Palavras-chave: Airport, BIM, Evaluation, Machine Learning.

1. INTRODUÇÃO

O desenvolvimento de um projeto aeroportuário possui elevada complexidade, tendo em vista a série de exigências projetuais e normativas a serem atendidas na fase de desenvolvimento da documentação técnica do projeto. No Brasil, a avaliação e aprovação dos projetos aeroportuários desenvolvidos pelas equipes de projeto são realizadas pela Empresa Pública Brasileira de Infraestrutura Aeroportuária (INFRAERO), Secretaria Nacional de Aviação Civil (SAC), Agência Nacional de Aviação Civil (ANAC), dentre outros órgãos.

No que se refere ao desenvolvimento de um projeto aeroportuário, existe uma série de pré-requisitos normativos que norteiam seu desenvolvimento. Tendo em vista a quantidade elevada de documentos normativos a serem considerados na fase desenvolvimento dos projetos, faz-se necessário que as equipes de projetistas possuam expertise equivalente para conceber um projeto em atendimento a todas as normas vigentes. Da mesma forma, a equipe de analistas dos órgãos competentes pela avaliação e aprovação desses projetos precisa dispor da maturidade adequada para realizarem a avaliação.

O problema desta pesquisa está situado exatamente no ponto de interseção entre a fase de desenvolvimento do projeto (competência dos projetistas) e a fase de avaliação e aprovação do projeto (competência dos analistas dos órgãos responsáveis), conforme apresentado na Figura 1.

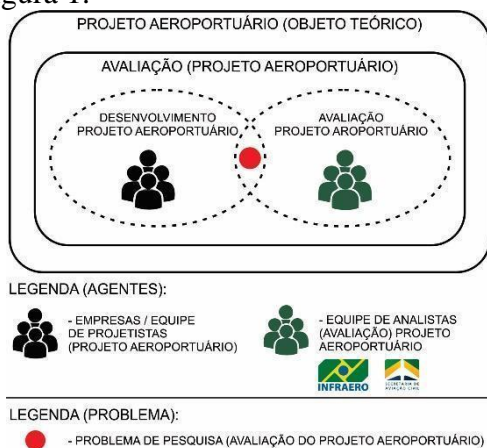


Figura 1 Problema da pesquisa abordado.

Fonte: Elaborado pelos autores.

A Figura 1 apresenta o problema desta pesquisa. Está se dá no âmbito da interação entre os projetistas e as equipes de analistas que é feita por meio de Pareceres Técnicos (no caso da SAC) e Relatório de Acompanhamento Técnico (RAT) no caso da INFRAERO. Estes visam comunicar o resultado das avaliações dos projetos submetidos. Ou seja, informar se o projeto atende ou não aos pré-requisitos normativos baseados nas normas, manuais e demais documentos vigentes.

Diante do problema exposto, essa pesquisa tem como objetivo apresentar os resultados preliminares de um método que visa otimizar o processo de avaliação de projetos aeroportuários, utilizando-se, para isso, técnicas de Aprendizagem de Máquina (AM), subárea de pesquisa do campo da Inteligência Artificial (IA). Este artigo visou treinar algoritmos de AM supervisionada a partir de dados contidos em modelos digitais 3D de projetos aeroportuários baseado na Modelagem da Informação da Construção (BIM), tirando proveito de recursos computacionais do BIM combinado com técnicas de AM, objetivando auxiliar os analistas de projetos aeroportuários na tomada de decisão com base na predição automática dos dados na fase de avaliação dos projetos, visando reduzir o tempo de análise.

Neste artigo, foram utilizados três algoritmos baseado na abordagem do aprendizado de máquina supervisionado, sendo eles: *K-Nearest Neighbor* (k-NN), *Decision Tree* (DT) e *Support Vector Machines* (SVM) a escolha desses três algoritmos, deu-se em função da variação das características que cada algoritmo possui na construção da função hipótese visando classificar novos dados.

A primeira seção deste artigo abrange a fundamentação teórica sobre o tema, desde o Processo de Projeto e o Processo de Avaliação de Projetos até a interação dessas fases com Inteligência Artificial, Aprendizagem de Máquina e a Modelagem da Informação da Construção (BIM). A segunda seção apresenta a metodologia estabelecida para o desenvolvimento desta pesquisa baseado no *Design Science Research* (DSR). A terceira seção expõe o processo de construção do artefato visando aperfeiçoar o processo de avaliação de projetos aeroportuários. No DSR, a expressão artefato pode ser entendida como, o

cumprimento de um propósito, ou adaptação a um objetivo. A quarta e última seção, apresenta os resultados parciais alcançados, através da instanciamento dos artefatos (03 modelos de AM supervisionado treinados) a partir dos dados contidos em projetos aeroportuários, avaliando o desempenho de cada modelo, assim como, expondo as possíveis aplicações desta abordagem para trabalhos futuros junto às considerações finais.

2. PROCESSO DE PROJETO E AVALIAÇÃO

Desde a década de 1950 surgiram investigações relacionadas a metodologia de projeto quando arquitetos e engenheiros, atentos ao cenário científico, passaram a aplicar novas técnicas no desenvolvimento de projeto para melhoria na qualidade do processo e dos seus produtos (SOBRAL et al, 2017).

Kalay (2004) expõe que o processo de projeto compreende três atividades principais que são realizadas de maneira interativa: analisar, sintetizar e prever/avaliar.

A primeira refere-se ao processo de analisar o problema e desenvolver um conjunto de objetivos que a solução proposta deve alcançar, juntamente com a lista de restrições pelas quais a solução deve obedecer (etapa concebida pelos projetistas). A segunda destina-se ao processo de sintetizar uma ou mais soluções que, com base na perspectiva do projetista, irá atingir os objetivos e respeitar as restrições projetuais (etapa realizada pelos projetistas). A terceira etapa representa o processo de prever e avaliar os vários desempenhos das soluções propostas visando verificar se são consistentes entre si e se, quando concretizadas, atingirão os objetivos estabelecidos (etapa realizada pela equipe de analistas de projeto aeroportuário).

Segundo Kalay (2004), a etapa destinada à avaliação é uma consequência direta e derivada da incerteza inerente ao processo de projeto. Como não existem fórmulas ou procedimentos que possam ser seguidos pelos projetistas que garantam que uma determinada solução de projeto atenderá aos objetivos e expectativas do projeto, este processo é necessariamente um processo de tentativa e erro. Neste as soluções são sintetizadas e seus desempenhos esperados

são previstos e julgados comparando-os com os objetivos e restrições do projeto (KALAY, 2004).

O processo de avaliação pode ser compreendido como uma atividade que realiza previsões e comparações visando determinar se as soluções atendem e cumprem os objetivos, ou não atendem. No caso da segunda condição, fornecendo informações sobre o que pode ser feito para melhorar o ajuste, implicando na modificação das soluções. Se os projetistas o fizerem, a busca por uma solução estará encerrada. Caso contrário, o ciclo de avaliação poderá ser repetido até que a solução seja atendida.

No Brasil, no tocante aos projetos aeroportuários avaliados pela equipe de analistas da SAC, a média de revisões de projeto até o atendimento completo das solicitações realizadas pela equipe de analistas é de aproximadamente cinco revisões. Em alguns casos, esse tempo tende a durar entre meses ou anos até o projeto ser completamente aprovado.

3. PROJETOS AEROPORTUÁRIOS

O desenvolvimento de um projeto aeroportuário (PA) por natureza possui uma elevada complexidade, a natureza dos requisitos a serem contemplados podem ser tanto de questões estéticas quanto funcionais (SILVESTRI, 2016).

O primeiro tipo refere-se ao conjunto e escopos mais significativos do empreendimento, bem como, seus parâmetros incluindo elementos físicos, financeiros e cronograma. Já o segundo tipo, trata-se de elementos relacionados aos requisitos operacionais e funcionais dos clientes e agentes para o conjunto da obra (SILVESTRI, 2015).

Uma vez que um projeto aeroportuário é desenvolvido por uma equipe de projetistas, este é submetido para avaliação junto aos órgãos competentes. A emissão inicial (R00) conta com um conjunto de documentos, tais como: pranchas de projeto, memoriais descritivos, memórias de cálculos, dentre outros. Mediante o envio de toda a documentação técnica, inicia-se o processo de avaliação por parte da equipe de analistas de PA.

No cenário atual, os analistas precisam analisar todos os documentos submetidos pela

equipe de projetistas individualmente, de maneira analógica, visando identificar tanto conformidades quanto não conformidades contidas no projeto. Além disso, o processo de avaliação tende a ser subjetivo, devido às diferentes perspectivas e expertises de conhecimento dos analistas, no momento da análise (GUEDES E ANDRADE, 2020).

Nos últimos anos, o desenvolvimento de projetos aeroportuários no Brasil baseado no uso do BIM foi alavancado devido à publicação do decreto de lei federal (Decreto nº10.306 de 2020). Este estabeleceu o uso do BIM na execução direta ou indireta de obras e serviços de engenharia realizada pelos órgãos e pelas entidades da administração pública federal. Este decreto faz parte da Estratégia Nacional de Disseminação do BIM (Decreto Lei Federal nº9.983 - 2019) e evidencia o interesse do governo federal no uso do BIM em território nacional. O Decreto destaca o uso do BIM no Ministério da Infraestrutura, especificamente no âmbito da Secretaria Nacional de Aviação Civil (SAC), para projetos de aeroportos regionais.

4. MODELAGEM DA INFORMAÇÃO DA CONSTRUÇÃO (BIM)

Segundo Sacks *et al.* (2018), o *Building Information Modeling* (BIM), é “...uma tecnologia de modelagem e conjunto associado de processos para produzir, comunicar, analisar modelos de construção...”.

Segundo Succar (2009), o BIM refere-se a um conjunto de políticas, processos e tecnologias que interagem, gerando uma metodologia para gerenciar os dados essenciais do projeto de construção e do projeto em formato digital ao longo do ciclo de vida do empreendimento.

Com as tecnologias que suportam o BIM, especificamente a interoperabilidade e modelagem paramétrica, é possível verificar se o modelo de construção (protótipo virtual do edifício) possui objetos corretos, convenções, proporções, dados associados ao modelo digital e outras estruturas necessárias para avaliação.

Dessa maneira, os dados contidos em projeto em BIM podem ser utilizados na etapa de avaliação, permitindo subsidiar os analistas de projeto aeroportuário. Para esta pesquisa a utilização do BIM está associada na etapa

avaliação dos dados utilizando técnicas de Aprendizagem de Máquina (AM) a serem discutidas nas seções seguintes.

5. INTELIGÊNCIA ARTIFICIAL E APRENDIZAGEM DE MÁQUINA

Desde a década de 1970, o campo de conhecimento da Inteligência Artificial (IA) começou a ser explorado de forma mais ampla para solucionar problemas reais (RUSSEL E NORVIG, 2010). Com base no grande volume de dados gerados, e a elevada complexidade dos problemas a serem resolvidos, fez-se necessário a utilização de abordagens mais sofisticadas. Induzir hipóteses a partir de um conjunto de dados, que é a experiência passada de algum problema, é o objetivo do Aprendizado de Máquina (FACELI, *et al.* 2011).

Machine Learning (ML), em português, Aprendizado de Máquina (AM) trata-se de uma subárea de pesquisa de IA. Segundo Mitchell (1997), o AM explora o uso de métodos computacionais a fim de adquirir novos conhecimentos, novas habilidades e novos meios de organizar o conhecimento existente. Esse mesmo autor afirma que o AM refere-se à capacidade de melhorar o desempenho na realização de alguma tarefa por meio da experiência. Segundo Montanõ (2016), os algoritmos de AM são organizados de acordo com o paradigma de aprendizado adotado para lidar com a tarefa.

As técnicas de AM podem ser compreendidas em linhas gerais através de três paradigmas: Aprendizado Supervisionado, Aprendizado Não-Supervisionado e Aprendizado por Reforço. Esta pesquisa faz uso do primeiro tipo, no qual, os dados contidos no modelo BIM do aeroporto (atributos de entrada rotulados) são utilizados como exemplos para treinamento dos algoritmos classificadores, possibilitando que os algoritmos realizem a predição de novos dados (novos projetos).

No AM, cada componente é descrito por um vetor de atributos de entrada (x), variável resposta (y) e uma função objetivo ($f = X \rightarrow Y$) que visa mapear a relação entre a variável resposta e o vetor de descrição do problema. Em linhas gerais, um sistema de AM possui: i) conjunto de treinamento composto de exemplos de treinamento $(x_1, y_1), (x_2, y_2) \dots (x_n, y_n)$, ii)

algoritmo de aprendizagem e iii) hipótese final através da função ($g = X \rightarrow Y$).

Para este artigo foi criado um conjunto de dados sintéticos (*dataset*) baseados nas dimensões reais dos Terminais de Passageiros (TPS) tipo M0, M1, M2 e M3 da INFRAERO / SAC denominado “Terminal Regional” destinados a atender a aviação regional no Brasil.

Desta maneira, foi concebido um *dataset* contendo uma variação de valores de 500 projetos (aptos e não aptos) com base em duas áreas do TPS: atendimento check-in e fila de embarque do check-in baseado nos requisitos quantitativos contidos no Memorial de Critérios e Condicionantes (MCC) - Arquitetura / TPS da INFRAERO (2008), assim como, visando beneficiar o cronograma previsto pela SAC (2021) referente à estrutura incremental das cinco entregas previstas para projetos aeroportuários que adotem a metodologia BIM.

6. METODOLOGIA

Este trabalho fez uso do *Design Science Research* (DSR), conhecido também como *Constructive Research*. A DSR trata-se de uma abordagem direcionada à solução de problemas, baseado em um processo rigoroso de: i) conceber artefatos visando solucionar problemas, ii) avaliar o que foi projetado e iii) comunicar os resultados alcançados. Neste artigo, estão sendo apresentados os resultados parciais das etapas i e ii.

A escolha para o uso dessa abordagem metodológica, deu-se em função de dois fatores, i) o problema de pesquisa corresponde a uma situação real referente ao processo de avaliação de projetos aeroportuários no Brasil, ii) o caráter da pesquisa se enquadra na categoria de inovação tecnológica, tendo em vista aplicar técnicas disruptivas como IA e AM para avaliação de projetos aeroportuários.

Em um primeiro momento foi criado um *dataset* contendo informações associadas aos modelos de TPS da INFRAERO / SAC. Os dados foram: Largura check-in (L1); Comprimento check-in (C1); Largura da fila de embarque (L2); comprimento da fila de embarque (C2) com o intuito de utilizar os dados para o treinamento e teste de três algoritmos de Aprendizagem de Máquina supervisionado.

A Figura 2 apresenta o fluxo estabelecido nesta pesquisa, desde a etapa 1 destinada a criação da base dados (baseada nos dados contidos nos modelos BIM dos TPS), a etapa 2 referente ao pré-processamento dos dados (extração das características e redução da dimensionalidade dos dados), divisão do conjunto de dados para treinamento (70% dos dados) e para a fase de teste (30% dos dados), a etapa 3 destinada ao treinamento dos algoritmos de aprendizagem supervisionada e a etapa 4 atribuída a avaliação dos algoritmos classificadores.

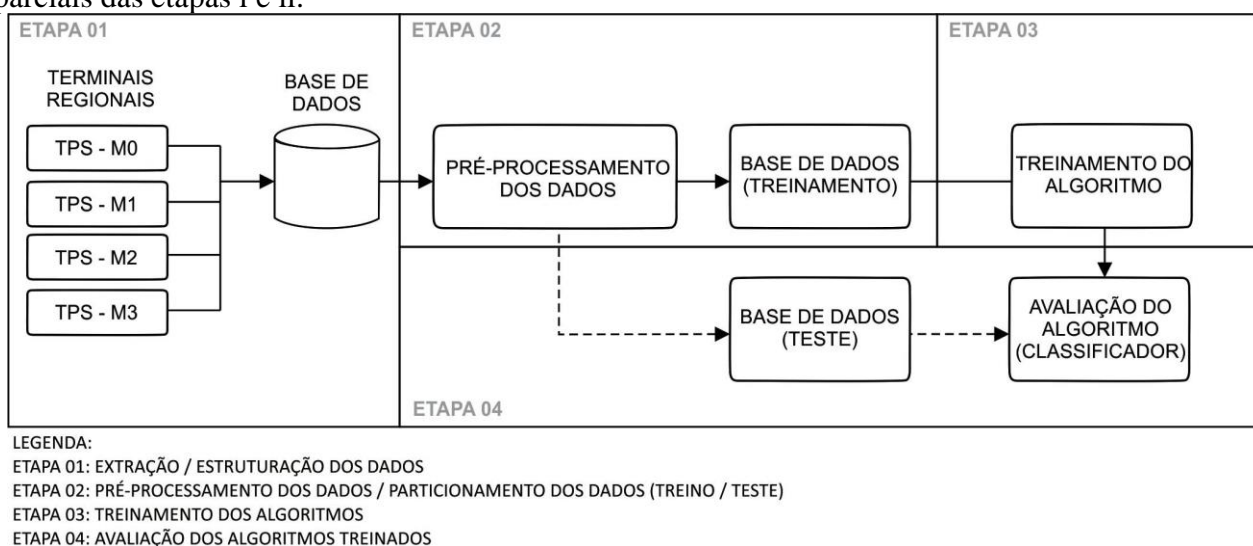


Figura 2 Fluxo das etapas desenvolvidas na metodologia proposta.

Fonte: Elaborado pelos autores.

Para este artigo, foram utilizados requisitos da área de check-in de um terminal de passageiros visando treinar os três algoritmos aprendizagem de máquina supervisionada. A Tabela 1 apresentada a seguir demonstra como os dados foram estruturados.

Tabela 1 - Dataset (recorte projeto 1 ao 5)

Projeto	L1	C1	L2	C2	Status
1	8,00	2,00	5,00	18,00	0
2	13,00	3,00	3,00	16,00	0
3	7,00	6,00	5,00	26,00	1
4	13,00	4,00	3,00	15,00	1
5	12,00	2,00	3,00	17,00	0

A coluna Projeto refere-se a descrição de dados de cada projeto, a coluna L1 (largura da área de atendimento do balcão de check-in) contém valores variáveis entre 2,00m (valor menor que o recomendado para um TPS tipo M0) e 16,00m (valor maior que o recomendável para um TPS tipo M3) com base no Manual de Critérios e Condicionantes de Planejamento Aeroportuário (INFRAERO, 2008).

A coluna C1 (comprimento da área de atendimento do check-in) contém valores entre 2,00m (valor menor que o recomendado para um TPS tipo M0) e 6,00m (valor maior que o recomendável para um TPS tipo M3).

A coluna L2 (largura da fila de embarque situada no check-in) contém valores entre 2,00m (valor menor que o recomendado para um TPS tipo M0) e 7,00m (valor maior que o recomendável para um TPS tipo M3).

A coluna C2 (comprimento de filas de embarques do check-in) contém valores entre 10,00m (valor menor que o recomendado para um TPS tipo M0) e 28,00m (valor maior que o recomendável para um TPS tipo M3).

Tendo em vista que o *dataset* foi criado com intuito de treinar algoritmos de aprendizagem supervisionada, onde a variável resposta é reconhecida como categórica, foi criado a coluna status destinada a apresentar o status para cada um dos 500 exemplos, tendo o valor 0 para os projetos “não aptos” e 1 para os projetos “aptos”.

Vale salientar que os valores de referências utilizados nas colunas L1, C1, L2 e C2, foram considerados valores condizentes com as dimensões dos TPS Regionais construídos e analisados pela INFRAERO / SAC, já as referências de limite aceitáveis e não aceitáveis dos valores, foram extraídos do MCC - Arquitetura TPS (INFRAERO, 2008).

A Figura 3 apresenta o esquema de expansibilidade adotado para os terminais regionais, assim como, o modelo em BIM desenvolvido pelos autores baseado no tipo M3.

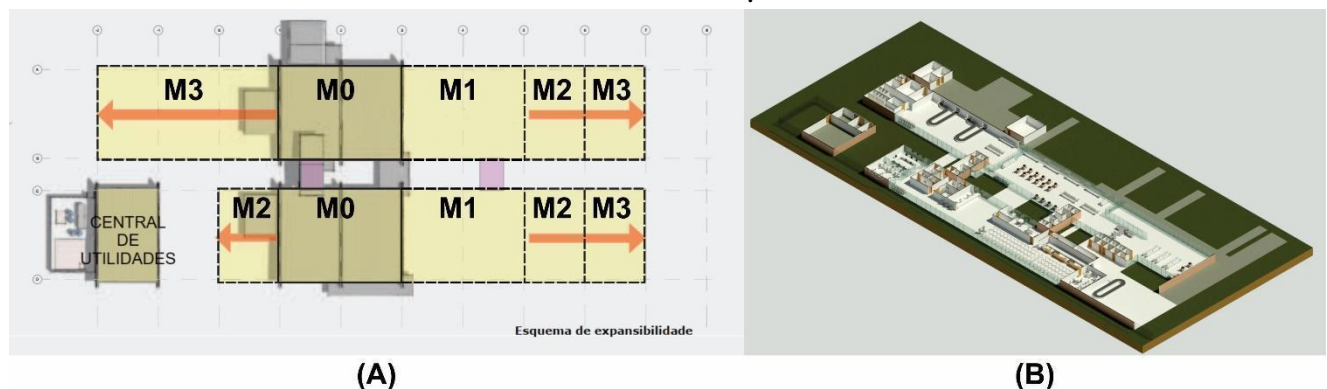


Figura 3 (A) esquema de expansão TPS Regionais (B) Modelo BIM TPS. Fonte: (A) INFRAERO / SAC (B)

Elaborado pelos autores.

7. RESULTADOS

Mediante a criação do *dataset* contendo os 500 exemplos de projetos com seus respectivos valores associados, sendo possível

realizar o treinamento dos três algoritmos de aprendizagem de máquina supervisionado *k-Nearest Neighbors* (k-NN), *Decision Tree* (DT) e *Support Vector Machine* (SVM).

Os três algoritmos foram implementados em linguagem *PYTHON* na

plataforma Google Collab executada em nuvem em um notebook com as seguintes configurações, processador Intel i7, CPU @2.20GHz e 8GB de RAM. Para a realização do treinamento de cada algoritmo, foram realizados ajustes específicos em seus respectivos hiperparâmetros.

No algoritmo k-NN foi estabelecido o valor de k-vizinhos mais próximo (k=3) tendo em vista que este ajuste possibilitou obter uma acurácia de 92,81%.

A Figura 4 apresenta os valores obtidos considerando a variação de k-vizinhos do algoritmo k-NN, tanto na fase de treinamento quanto na fase de validação.

Pela visualização da Figura 4, é possível perceber que o valor k=3 conseguiu alcançar uma melhor acurácia tanto na etapa de treinamento quanto na etapa de validação. Os demais hiperparâmetros deste algoritmo tais como: peso (*weight*), tamanho da folha (*leaf_size*), métrica (*metric_params*), argumentos e trabalhos (*n-jobs*) foram utilizados os valores *default* da biblioteca Scikit-learn: Machine Learning in Python, Pedregosa *et al.* (2011).




Figura 4 - Variação de k-vizinhos. Fonte: Elaborado pelos autores

Após o treinamento do algoritmo k-NN foi possível realizar o treinamento no algoritmo *Decision Tree* (DT), Árvore de Decisão em português.

Para o algoritmo DT, foi utilizado o mesmo *dataset*, assim como, foi possível realizar ajustes nos hiperparâmetros do algoritmo, a fim de que o mesmo pudesse alcançar uma melhor acurácia.

Desta maneira foi possível ajustar os hiperparâmetros de profundidade máxima da árvore (*max_depth*) = 3,00, limites de nós da árvore (*max_leaf_nodes*) = 4,00 visando obter um melhor desempenho. Os demais hiperparâmetros, foram considerados os valores *default* da biblioteca Scikit-learn. Desta maneira, o algoritmo DT conseguiu alcançar um percentual de acurácia de 99,40%.

Por fim, foi utilizado o mesmo *dataset* para treinar o algoritmo *Support Vector Machines* (SVM) Máquina de Vetor de Suporte, em português. Para este algoritmo, foi considerando todos os valores *default* da biblioteca Scikit-learn, sendo possível o algoritmo SVM conseguiu alcançar uma acurácia de 95,20%.

Uma vez treinados os três algoritmos, foi possível medir seus respectivos desempenho a partir de algumas métricas, sendo: acurácia, precisão, *recall* e *F1-score*. A escolha dessas métricas deu-se em função de poder avaliar os modelos treinados além de sua performance geral do ponto de vista da acurácia, mais também, poder analisar a variação dos percentuais obtidos com relação as classificações obtida com relação a precisão e *recall*, assim como, obter o *F1-score*. A Tabela 2 apresenta os resultados alcançados.

Tabela 2 – Desempenho dos algoritmos

<i>Modelo</i>	<i>Accuracy</i>	<i>Precision</i>	<i>Recall</i>	<i>F-1</i>
k-NN	0.93	0.89	0.96	0.92
DT	0.99	0.99	0.99	0.99
SVM	0.95	0.95	0.95	0.95

A acurácia foi definida como a razão entre a taxa de acertos em relação ao total de amostras. A equação (1) apresentada abaixo demonstra como foi calculado a acurácia.

$$Acurácia = \frac{VP + VN}{VP + VN + FP + FN} \quad (1)$$

Legenda:

VP: verdadeiros positivos (classificação correta da classe positiva);

VN: verdadeiros negativos (classificação correta da classe negativa);

FP: falsos positivos (erro em que o modelo previu a classe positiva quando deveria ser classe negativa);

FN: falsos negativos (erro em que o modelo previu a classe negativa quando deveria ser classe positiva).

A precisão refere-se a quanto os dados classificados como positivos realmente são positivos, a equação (2) demonstra como foi calculado a precisão.

$$Precisão = \frac{VP + VN}{VP + VN + FP + FN} \quad (2)$$

O *recall*, também conhecido como taxa de verdadeiros positivos, é utilizado com o objetivo de identificar todos os positivos, demonstrando o percentual de quanto os positivos foram identificados pelas previsões positivas. A equação (3) apresenta como foi calculado o *recall*.

$$Recall = \frac{VP}{VP + VN} \quad (3)$$

Por fim, a métrica F-1 *Score*, representa a média entre a precisão e o *recall*, a equação (4) apresentada abaixo demonstra como se obteve os resultados.

$$F1 = 2 * \frac{Precisão * Recall}{Precisão + Recall} \quad (4)$$

8. CONSIDERAÇÕES FINAIS

Este artigo apresentou resultados preliminares de uma pesquisa de doutorado em desenvolvimento. Os resultados alcançados até o momento mostram o potencial que a utilização de algoritmos de aprendizagem de máquina proporciona na etapa de avaliação dos projetos aeroportuários. Para este artigo, foi criado um *dataset* sintético baseado apenas em parâmetros quantitativos relativos a projeto aeroportuário. Os resultados alcançados pelos três algoritmos k-NN, DT e SVM demonstram a capacidade de classificação dos algoritmos de aprendizagem supervisionada, alcançando percentuais de acurácia acima de 90%.

O resultado alcançado de 99,40% com o algoritmo DT demonstra a sua capacidade de identificar as classes dos dados “não aptos” e “aptos” através de seu funcionamento baseado no ganho de informação utilizando o conceito de entropia relativo à classificação booleana.

A utilização de técnicas de aprendizagem de máquina no processo de avaliação de projetos aeroportuários abre um novo horizonte para que as equipes de analistas de projetos aeroportuários, possam extrair diversas informações contidas nos modelos BIM de projetos aeroportuários visando transpor os dados para um contexto de AM, possibilitando promover um enriquecimento semântico na etapa de avaliação dos projetos.

O potencial dos algoritmos de AM em identificar padrões contidos em grandes conjuntos de dados possibilita que os analistas de projeto aeroportuários possam tirar proveito, utilizando os dados provenientes de projetos aeroportuários, utilizando esses dados para treinar os algoritmos, criando modelos capazes de realizar previsões através de um conjunto de novos dados.

Ao longo do desenvolvimento da pesquisa, foi notado que existe uma série de documentos relacionados ao estabelecimento de critérios quantitativos (normas, manuais, portarias, dentre outros), assim como, uma série de documentos relacionados a critérios qualitativos, sendo este segundo grupo, relativos a parâmetros que extrapolam os requisitos de dimensionamento dos espaços projetados em um aeroporto, se tratando de questões relativas à percepção dos visitantes e funcionários de um aeroporto relacionado a níveis de serviço, nível de conforto, assim como, indicadores de qualidade, tais como: indicadores *Airports Council International* (ACI), *Airport Development Reference Manual* (ADRM) do IATA (1991), dentre outros.

Para desdobramentos futuros, os autores recomendam realizar o cruzamento de dados do grupo de requisitos quantitativos com os requisitos qualitativos, a fim de verificar se os algoritmos de aprendizagem de máquina conseguirão identificar padrões e

realizar previsões combinando esses dois grupos, assim como, experimentar a utilização de diferentes arquiteturas e modelos que possuam a capacidade de se adaptar a diferentes classes de dados, tais como Redes Neurais Artificiais (RNA), Redes Multilayer Perceptron (MLP), Redes Neurais Recorrentes (LSTM, GRU, QRNN), bem como, algoritmos de Aprendizagem Profunda (*Deep Learning*).

REFERÊNCIAS

- Decreto nº 9,983 (2019). De 22 de agosto de 2019. Disponível em: <http://www.planalto.gov.br/ccivil_03/_ato2019-2022/2019/Decreto/D9983.htm> acesso em ago/22.
- F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and E. Duchesnay (2011). *Scikit-learn: Machine learning in Python. Journal of Machine Learning Research*, v.12: p. 2825-2830.
- Faceli, K.; Iorena, A. C.; Gama, J.; Carvalho, A. C. P. L. F. de. (2011). *Inteligência artificial: uma abordagem de aprendizado de máquina*. Rio de Janeiro: LTC.
- Guedes Í.; Andrade M. (2020). *Standardization of Airport Architectural Design Projects BIM-based for Code Checking*. p. 490-498. In: Congresso SIGraDi 2020. São Paulo: Blucher.
- IATA (1991). *Airport Development Reference Manual*, International Air Transport Association, Genebra.
- INFRAERO (2008). *Memorial de Critérios e Condicionantes - Arquitetura / TPS* código GE.01/201.75/00947/02.
- Kalay, Y. (2004). *Architecture's new media*. The MIT Press, Cambridge.
- Mitchell, T. M (1997). *Machine Learning*. McGraw-Hill, Inc., New York, NY, USA, 1 edition.
- R. Sacks, C. Eastman, G. Lee, and P. Teicholz (2018). *BIM Handbook: A Guide to Building Information Modeling for Owners, Designers, Engineers, Contractors, and Facility Managers*. Hoboken, NJ, USA: Wiley.
- SAC (2021). *Manual de Projetos Aeroportuários* [livro eletrônico]: volume único. 1. Ed. Brasília, DF: Secretaria Nacional de Aviação Civil.
- Silvestri, A. L. S. (2016). *Termo de referência para gestão de projetos arquitetônicos de terminais aeroportuários regionais de passageiros*. Tese de Doutorado, Instituto de Arquitetura e Urbanismo, Universidade de São Paulo, São Carlos.
- Sobral, R.; azevedo, G.; Guimarães, M. (2017). *Design Methods Movement: as origens das pesquisas sobre métodos de projeto*. p. 27-42. In: Design & Complexidade; Complexidade. São Paulo: Blucher.
- Succar, B. (2009). *Building Information Modelling Framework: a research and delivery foundation for industry stakeholders*. Automation in Construction, v. 18, n. 3, p. 357-375.